

ГУАП

КАФЕДРА № 42

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ
ПРЕПОДАВАТЕЛЬ

доцент

должность, уч. степень,
звание

подпись, дата

Н.В. Богословская

инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №4

по курсу: Большие данные

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ гр. № 4321

подпись, дата

Г.В. Буренков

инициалы, фамилия

Санкт-Петербург 2026

1 Цель работы

Изучение методов кластеризации с применением встроенных компонентов Logiном и узлов Python.

2 Задание

1. Для двух наборов: Высшее образование.xls, Здравоохранение.xls реализуйте кластеризацию алгоритмами EM, k-mean, g-means.
2. Для набора transactions_diy.lgd реализуйте кластеризацию транзакций [4, 5].
3. Выполните оценку качества всех полученных моделей.
4. Предложите интерпретацию полученных кластеров.
5. Разработайте визуальные отчеты пользователю для изучения полученных кластеров.

3 Ход выполнения задания

Для выполнения первого задания были установлены два документа и построены схемы, представленные на рисунках 1-2.




Рисунок 1 – Схема для файла Высшего образования




Рисунок 2 – Схема для файла Здравоохранения

В первую очередь обсудим файл Высшего образования. На рисунке 3 представлен метод локтя – для создания диаграммы количества кластеров по квадрату расстояния был запущен повторяющийся цикл, показанный на рисунке 4. На рисунке 5 квадрат расстояния перестает снижаться несущественно после 5 кластеров, поэтому остановимся на значении 5.




Рисунок 3 – Схема метода локтя

Выход				
#	Квадрат расстояния	Сумма	Начальное число кластеров	Число итераций
1	433,13		2	8
2	304,83		3	7
3	243,43		4	6
4	219,52		5	5
5	191,30		6	4
6	173,37		7	3
7	156,52		8	2
8	148,96		9	1

Рисунок 4 – Результат работы для различного количества кластеров




Рисунок 5 – Диаграмма отношения расстояния к сумме

В блоке кластеризация, заданное количество кластера было взято число 5.

Профили кластеров k-means до исключения									
Фильтрация									
#	Метка поля	Тип	Итого	Кластер 0 %	Кластер 1	Кластер 2	Кластер 3	Кластер 4	
1	9.0 1. Число образ...	○	48	39%	1,2%	28%	28%	3,7%	
2	9.0 4. Выпуск бана...	○	55		99,12	47	52	71	
3	9.0 3. Прием на обу...	○	58		96,9	45	47	97,3	
4	9.0 2. Численность ...	○	60		94,6	48	54	97,3	
5	9.0 5. Численность ...	○	87		98,9	48	55	97,3	
					99,12	68	68	97,3	

Рисунок 6 – Профили кластеров до исключения




Рисунок 7 – Качество кластеризации (индекс силуэта) K-means

№	Имя	Метка	Значение
1	9.0 SilhouetteCoefficient	Индекс силуэта	0,27
2	ab Quality	Качество кластеризации	Среднее

Рисунок 8 – Оценка по индексу

После анализа было понятно, что значения имеют аномалии и пришлось провести фильтрацию данных. На рисунке 8 и 9 показан результат качества и удаленные значения.

12 Номер строки	9.0 Индекс силуэта
260	-0,01131806531
250	-0,00320800023
500	0
240	0,03885960471
230	0,04482654263
220	0,0569486654
210	0,06635498692
200	0,06746264283
190	0,0709531648
180	0,0730401025

Рисунок 9 – Аномальные значения

Профили кластеров k-means после исключения						
Фильтрация						
#	Метка поля	Тип	Итого	Кластер 0	Кластер 1	Кластер 2
			100%	35%	3,8%	30%
1	9.0 1. Число образ...	○	54	40	74	46
2	9.0 2. Численность ...	○	58	46	97,2	68
3	9.0 3. Прием на обу...	○	54	43	97,2	61
4	9.0 4. Выпуск бака...	○	51	38	97,2	57
5	9.0 5. Численность ...	○	62	45	97,2	48

Рисунок 10 – Профили кластеров после исключения




Рисунок 11 – Качество кластеризации (индекс силуэта) K-means

№	Имя	Метка	Значение
1	9.0 SilhouetteCoefficient	Индекс силуэта	0,34
2	ab Quality	Качество кластеризации	Среднее

Рисунок 12 – Оценка по индексу

Оценка качества кластеризации, выполненной методом k-means для документа «Высшее образование», проводилась с использованием индекса силуэта. Полученные значения преимущественно располагаются в положительной области — в интервале от 0,15 до 0,65. Это свидетельствует о том, что сформированные группы достаточно хорошо отделены друг от друга, а объекты внутри каждой из них обладают высокой степенью сходства. Лишь незначительная часть значений приближается к нулю, что указывает на наличие отдельных объектов, находящихся на границе между кластерами. Полное отсутствие отрицательных значений подтверждает корректность проведённой кластеризации и обоснованность выделения именно трёх групп.

В основе разделения лежали ключевые показатели, характеризующие региональные системы высшего образования: число образовательных организаций, численность студентов, приём на обучение, выпуск бакалавров, а также численность профессорско-преподавательского состава. На основании этих признаков все регионы были распределены по трём кластерам, каждый из которых демонстрирует специфический профиль развития.

Первый, самый многочисленный кластер, объединяет 42% объектов. Для этих регионов характерны значения всех показателей, близкие к средним по выборке, что позволяет интерпретировать их как группу со средним уровнем развития высшего образования. Второй кластер (26% регионов) включает территории с более низкими значениями большинства показателей; здесь наблюдаются менее развитая образовательная инфраструктура и меньшие масштабы подготовки кадров. Третий кластер (27%) составляют регионы с повышенными показателями численности студентов, приёма и

выпуска бакалавров, что отражает высокий уровень развития системы высшего образования и наличие масштабной образовательной инфраструктуры.

Для набора G-means была проведена аналогичная работа, на рисунках 13-14 изображен диаграмма индексов силуэтов и результат.




Рисунок 13 – Качество кластеризации (индекс силуэта) G-means

Индексы силуэтов		Индекс силуэта		
№	Имя	Метка	Значение	
1	9.0 SilhouetteCoefficient	Индекс силуэта	0,31	
2	ab Quality	Качество кластеризации	Среднее	

Рисунок 14 – Оценка по индексу

Анализ графика индекса силуэта G-means показывает, что значения в основном лежат в положительной области (0,15–0,7), а основная их часть сосредоточена в интервале 0,3–0,5. Это говорит о хорошем разделении кластеров и высокой однородности объектов внутри них. Отдельные

значения вблизи нуля указывают на незначительное количество пограничных объектов, а отсутствие отрицательных значений подтверждает корректность кластеризации.

По ключевым показателям (число организаций, численность студентов, приём и выпуск) выделены три кластера. Первый (около 49% регионов) объединяет территории со средними значениями, что соответствует среднему уровню развития высшего образования. Второй (около 45%) включает регионы с более низкими показателями, характеризующиеся менее развитой образовательной инфраструктурой.

Третий кластер является самым малочисленным (3–4% регионов) и демонстрирует значительно более высокие значения численности студентов, приёма и выпуска. Это позволяет рассматривать его как группу крупных образовательных центров с развитой системой высшего образования и высокой концентрацией ресурсов.

Перейдем к здравоохранению на рисунке 2. На рисунке 15 получился результат метода локтя.

9.0 Квадрат расстояния Сумма	12 Текущая итерация	12 Количество кластеров
219,98	0	2
162,77	1	3
134,56	2	4
117,29	3	5
105,34	4	6
92,52	5	7
85,18	6	8
80,48	7	9

Рисунок 15 – Результат метода локтя




Рисунок 16 – Результат метода локтя.

На основе анализа был взято три центра кластера для вычислений. На рисунках 17-18 изображен результат качества кластеризации для метода




Рисунок 17 – Качество кластеризации здравоохранения для em-meap

Индексы силуэтов		Индекс силуэта	
№	Имя	Метка	Значение
1	9.0 SilhouetteCoefficient	Индекс силуэта	0,43
2	ab Quality	Качество кластеризации	Среднее

Рисунок 18 – Оценка качества кластеризации здравоохранения

Оценка индекса силуэта для EM-mean показывает, что значения преимущественно лежат в положительной области (0,1–0,57), что свидетельствует о хорошем разделении кластеров и высокой однородности объектов внутри них. Небольшое количество значений вблизи нуля указывает на отдельные пограничные объекты, а отсутствие отрицательных значений подтверждает корректность распределения.

Первый кластер — самый крупный (около 66% регионов) — объединяет территории со средними показателями мощности учреждений и обеспеченности кадрами, что соответствует среднему уровню развития здравоохранения. Второй кластер (около 11%) характеризуется более высокими значениями этих показателей и представляет группу регионов с более развитой медицинской инфраструктурой.

Третий кластер (около 10%) включает регионы с более низкими показателями обеспеченности ресурсами или мощностью организаций, что позволяет отнести их к территориям с относительно менее развитой системой здравоохранения.




Рисунок 19 – Визуализатор профиля кластера




Рисунок 20 – Схема для второго задания

	Скобяные ...	Стойматериалы		Столярные изделия		Товары для дачи и отдыха		Электротовары	
	Кол-во	Сумма	Кол-во	Сумма	Кол-во	Сумма	Кол-во	Сумма	Кол-во
0	83.00	184,783.00	1,008.00	30,519.00	30.00	33,008.00	12.00	11,716.00	54.00
1	201,976.00	78,388,415....	433,272.00	51,563,339....	221,363.00	14,645,429....	19,584.00	30,234,300....	228,076.00
2	607.00	2,242,943.00	14,453.00	276,972.00	1,826.00	206,875.00	320.00	176,166.00	1,511.00
3	2.00	12,535.00	58.00	17,404.00	12.00	5,663.00	47.00	12,321.00	77.00
4	46.00	92,391.00	446.00	76,372.00	153.00	420,996.00	256.00	19,877.00	179.00
Итого:	202,714.00	80,901,067....	449,237.00	51,964,606....	223,384.00	15,311,771....	20,219.00	30,454,380....	229,697.00

Рисунок 21 – Результат для значений диапазона 4-5