

ЛАБОРАТОРНАЯ РАБОТА 4

Кластеризация — объединение объектов или наблюдений в непересекающиеся группы, называемые кластерами [1].

Кластеризация — 1) группировка объектов на основе близости их свойств; каждый кластер состоит из схожих объектов, а объекты разных кластеров существенно отличаются; 2) процедура, которая любому объекту $x \in X$ ставит в соответствие метку кластера $y \in Y$.

Кластеризацию используют, когда отсутствуют априорные сведения относительно классов, к которым можно отнести объекты исследуемого набора данных, либо когда число объектов велико, что затрудняет их ручной анализ.

Постановка задачи кластеризации сложна и неоднозначна, так как:

- оптимальное количество кластеров в общем случае неизвестно;
- выбор меры «похожести» или близости свойств объектов между собой, как и критерия качества кластеризации, часто носит субъективный характер.

Важно понимать, что сама по себе кластеризация не приносит каких-либо результатов анализа. Для получения эффекта необходимо провести **содержательную интерпретацию** каждого кластера. Такая интерпретация предполагает присвоение каждому кластеру емкого названия, отражающего его суть, например «Разведенные женщины с детьми», «Дачники», «Работающие студенты» и т. д. Для интерпретации аналитик детально исследует каждый кластер: его статистические характеристики, распределение значений признаков объекта в кластере, оценивает мощность кластера — число объектов, попавших в него. Интерпретация значительно облегчается, если имеются способы представления результатов кластеризации в специализированном виде.

На сегодня предложено несколько десятков алгоритмов кластеризации и еще больше их разновидностей. Несмотря на это в Data Mining в первую очередь применяются алгоритмы, которые понятны и просты в использовании. В Logitom это алгоритмы k-means, g-means, EM кластеризация и кластеризация транзакций.

Практические правила кластеризации

Чтобы применять кластеризацию корректно и снизить риск получения результатов моделирования, не имеющих никакого отношения к действительности, необходимо придерживаться следующих правил.

Правило 1. Перед кластеризацией четко обозначьте цели ее проведения: изучение данных, облегчение дальнейшего анализа, сжатие данных, прогнозирование, обнаружение аномалий. Кластеризация сама по себе не представляет особой ценности.

Правило 2. Выбирая алгоритм, убедитесь в том, что он корректно работает с теми данными, которыми вы располагаете для кластеризации. В частности, если присутствуют категориальные признаки, удостоверьтесь, что та реализация алгоритма, которую вы используете, умеет правильно обрабатывать их. Это особенно актуально для алгоритмов k-means и g-means, EM (впрочем, и для других, основанных на метриках), в большинстве случаев, применяющих евклидову меру расстояния. Если алгоритм не умеет работать со смешанными наборами данных, постарайтесь сделать набор данных однородным, то есть отказаться от категориальных или числовых признаков или выполнить кодирование признаков.

Правило 3. Обязательно проведите содержательную интерпретацию каждого полученного кластера: постарайтесь понять, почему объекты были сгруппированы в определенный кластер, что их объединяет? Для этого можно использовать визуальный анализ, графики, кластерограммы, статистические характеристики кластеров, карты. Полезно каждому кластеру дать емкое название, состоящее из нескольких слов. Встречаются ситуации, когда алгоритм кластеризации не выделил никаких особых групп. Возможно, набор данных и до кластеризации был однороден, не распадавался на изолированные подмножества, а кластеризация подтвердила эту гипотезу.

Таким образом, не существует единого универсального алгоритма кластеризации. При использовании любого алгоритма важно понимать его достоинства, недостатки и ограничения. Только тогда кластеризация будет эффективным инструментом в руках аналитика.

Сегментация клиентов телекоммуникационной компании

В такой высокотехнологичной отрасли, как телекоммуникации, методы и подходы Data Mining получили широкое применение. Решаемые задачи прежде всего связаны с программами лояльности и удержанием существующей клиентской базы, а также привлечением новых потребителей услуг.

В биллинговых системах телекоммуникационных компаний накапливаются большие объемы данных. В первую очередь это информация об абонентах и статистика использованных услуг.

Далее рассмотрен пример кластерного анализа, с ним полезно познакомиться, а в качестве самостоятельной работы необходимо выполнить задания из **Требования к отчету**.

Постановка задачи. Руководство филиала региональной телекоммуникационной компании, предоставляющей на рынке услуги мобильной связи, поставило задачу сегментации абонентской базы. Целями сегментации являются:

- построение профилей абонентов путем выявления их схожего поведения в частоте, длительности и времени звонков, а также ежемесячных расходов;
- оценка наиболее и наименее доходных сегментов.

Эта информация может в дальнейшем использоваться для:

- разработки маркетинговых акций, направленных на определенные группы клиентов;
- разработки новых тарифных планов;
- оптимизации расходов по адресной sms-рассылке о новых услугах и тарифах;
- предотвращения оттока клиентов другие компании.

Данные (mobile.txt), взятые из биллинговой системы за несколько месяцев, представляют собой набор со следующими полями:

- Возраст клиента;
- Среднемесячный расход;
- Средняя продолжительность разговора;
- Звонков днем за месяц;
- Звонков вечером за месяц;
- Звонков ночью за месяц;
- Звонков в другие города;
- Звонков в другие страны;
- Доля звонков на стационарные телефоны;
- Количество sms.

Были отобраны только активные абоненты, которые регулярно пользовались услугами сотовой связи в течение последнего месяца.

В учебном пособии по машинному обучению [2] рассмотрен метод для оптимального определения K (количества кластеров): «Метод локтя — это метод, который мы используем для определения количества центроидов (k) для использования в алгоритме кластеризации k -средних. В этом методе для определения значения k мы непрерывно выполняем итерации от $k = 1$ до $k = n$ (здесь n - гиперпараметр, который мы выбираем в соответствии с нашими требованиями). Для каждого значения k мы вычисляем значение внутрикластерной суммы квадратов (WCSS)».

На рис.1 пример сценария использования метода локтя.




Рисунок 1 – Вычисление количества кластеров методом «локтя»

Для полученного количества кластеров (7) был использован алгоритм k-means и рассчитана доходность сегментов – рис.2.




Рисунок 2 – Сценарий сегментирования клиентов биллинговой системы

В визуализаторе **Профили кластеров** можно посмотреть общую структуру сформированных кластеров [3].

В визуализаторе отображаются все рассматриваемые показатели вместе с характером влияния их на состав кластера. Основным фактором, определяющим состав кластера, является значимость свойств, выраженная в процентах.

Общая значимость рассматриваемого поля определяется вариабельностью ее параметров.

Для каждого рассматриваемого свойства в кластере вычисляется: среднее, стандартное отклонение, стандартная ошибка и др. Приводится накопительная диаграмма.

Можно транспонировать таблицу, расположив кластеры в столбцах. Если необходимо упорядочить столбцы по номеру кластера, то выполнить это можно простым перетаскиванием. Выделение нескольких ячеек в строке **Возраст** для сравнения возможно при нажатой **клавише Ctrl**. Справа от таблицы будет проведено сравнение кластеров по показателю Возраст (рис. 3).




Рисунок 3 – Профили полученных кластеров

Проверка качества кластеризации выполнена с помощью компонента **meta-silhouettes**. Компонент доступен при подключении ссылки на библиотеку компонентов loginom_sklearn_meta (рис.4).




Рисунок 4 – Ссылка на библиотеки компонентов

Для настройки входных портов компонента meta-silhouettes необходимо сформировать метки кластеров. Используйте компонент **Параметры полей** (рис.5) для исключения всех полей, кроме поля Номер кластера, преобразования поля к текстовому формату и передачи его на входной порт meta-silhouettes.




Рисунок 5 – Использование meta-silhouettes из библиотеки loginom_sklearn_meta

Компонент **Кластерные силуэты** позволяет сформировать набор данных для графического построения кластерных силуэтов (рис.6) и проведения общей оценки качества кластеризации, выполненной внешним алгоритмом.

Оценка качества кластеризации, выполненная с помощью компонента **Кластерные силуэты**, показала удовлетворительное качество кластеризации (рис.7).




Рисунок 6 – Визуальное представление качества кластеризации




Рисунок 7 – Оценка качества полученной модели

В процессе выполнения кластерного анализа выявляются статистические связи между анализируемыми переменными, которые указывают на схожесть переменных, затем происходит объединение выявленных факторов в группы на основе уровня различий между ними.

С учетом заявленных целей сегментации: определение профилей отдельных групп абонентов и вычисление ежемесячных расходов с оценкой наиболее и наименее доходных сегментов, можно предложить вариант интерпретации результатов кластерного анализа - табл.1.

Таблица 1 – Интерпретация результатов кластерного анализа

Кластер	Условное наименование	Мощность кластера	Прибыльность кластера
0	Молодежь, мало пользующаяся услугами	10%	5,17%
1	Активная группа зрелого возраста	17%	31,13%
2	VIP-клиенты	10%	4,04%
3	«Малоговорящие» пенсионеры	24%	1,38%
4	Работающие люди среднего возраста	14%	12,18%
5	Активная молодежь	14%	36,53%
6	Основная молодежь	10%	9,58%

Требования к отчету:

1. Для двух наборов: **Высшее образование.xls**, **Здравоохранение.xls** реализуйте кластеризацию алгоритмами EM, k-mean, g-means.
2. Для набора **transactions_diy.lgd** реализуйте кластеризацию транзакций [4, 5].
3. Выполните оценку качества всех полученных моделей.
4. Предложите интерпретацию полученных кластеров.
5. Разработайте визуальные отчеты пользователю для изучения полученных кластеров.

Для установки библиотек используйте материалы лекции. Там же подробно рассмотрена реализация алгоритма «локоть».

Источники:

1. Loginom. Кластеризация. URL: <https://examples.loginom.ru/clustering/> (дата посещения 09.01.26)
2. Machine Learning Tutorial. Elbow Method for optimal value of k in KMeans. URL: <https://www.geeksforgeeks.org/elbow-method-for-optimal-value-of-k-in-kmeans/> (дата посещения 09.01.26)
3. Loginom. Профили кластеров. URL: <https://help.loginom.ru/userguide/visualization/cluster-profiles/index.html> (дата посещения 09.01.26)
4. Loginom. Кластеризация транзакций. URL: <https://help.loginom.ru/userguide/processors/datamining/transaction-clustering.html?ysclid=mm6f66f2q3680938288> (дата просмотра 28.02.2026)
5. Loginom. Кластеризация категориальных данных. URL: <https://loginom.ru/blog/clope?ysclid=mm7zf4mqr1756234230> (дата просмотра 01.03.2026)