

ГУАП

КАФЕДРА № 42

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ
ПРЕПОДАВАТЕЛЬ

доцент

должность, уч. степень,
звание

подпись, дата

Н.В. Богословская

инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №6

по курсу: Большие данные

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ гр. № 4321

подпись, дата

Г.В. Буренков

инициалы, фамилия

Санкт-Петербург 2026

1 Цель работы

Изучение метода линейной и логистической регрессии в Logitom через python.

2 Задание

1. Выполнить задания в проекте и сравните качество моделирования встроенного в Logiном компонента Линейная регрессия и моделей линейной регрессии Python. Написать свои выводы по качеству моделей. Какую модель из трех исследованных вы в итоге выберете и почему
2. Выполнить регрессионный анализ датасета с учетом временного изменения о числе амбулаторно-поликлинических организаций в Российской Федерации за 19 лет. Выполнить регрессионный анализ датасета с учетом временного изменения числа амбулаторно-поликлинических организаций.
3. Требуется, используя 70% случайную выборку клиентов, создать модель для оценки склонности клиентов к приобретению продуктов новой линии. Выбросы и экстремальные значения оставить без изменения.

3 Ход выполнения задания

Сперва были подготовлены данные в модуле подготовка данных, представленный на рисунке 1.




Рисунок 1 – Модуль подготовка данных

3.1 Линейная регрессия через Logitom

На рисунке 2 изображена схема для первого задания.




Рисунок 2 – Схема для линейной регрессии через Logitom

Была разработан алгоритм для модели с параметрами по умолчанию без нормализации. На рисунках 3-6 изображен разбор данных модели.

regression metrics (выполнение) • Быстрый просмотр			
Выходной набор данных			
#	ab Метрика	9.0 Значение	
1	r2	0,70	
2	explained_variance	0,70	
3	max_error	47 052 667,30	
4	mean_absolute_error	1 547 173,74	
5	mean_squared_log_error		
6	mean_squared_error	7 101 666 280 135,40	
7	median_absolute_error	976 637,13	
8	mean_absolute_percentage_error	0,22	
9	d2_absolute_error_score	0,46	

Рисунок 3 – Результат регрессионной метрики для модели по умолчанию без нормализации

Выходной набор данных			
#	ab Метрика	9.0 Значение	
1	r2	0,61	
2	explained_variance	0,65	
3	max_error	36 566 194,77	
4	mean_absolute_error	2 126 493,71	
5	mean_squared_log_error		
6	mean_squared_error	12 145 816 843 488,74	
7	median_absolute_error	1 299 278,45	
8	mean_absolute_percentage_error	0,21	
9	d2_absolute_error_score	0,40	

Рисунок 4 – Результат регрессионной метрики для модели скоринг через тестовую выборку




Рисунок 5 – Диаграмма рассеяния для модели через тестовую выборку

Модель линейной регрессии показала качество - коэффициент детерминации R^2 на тестовой выборке равен 0.61, а средняя ошибка 2.126.

По аналогии с модулем через Loginom был собран вариант через Python Kits для линейной регрессии. На рисунке 6 показана схема модели через Python. На 7-8 показаны ее метрики оценки качества регрессионной модели. На рисунках 9-10 показан результат через кастомный энкодер




Рисунок 6 – Схема для линейной регрессии через Python

Выходной набор данных			
#	ab Выборка	ab Метрика	9.0 Значение
1	train	MAE	1 554 879,56
2	train	MSE	7 115 547 495 121,98
3	train	RMSE	2 667 498,36
4	train	R2	0,70
5	test	MAE	2 106 543,47
6	test	MSE	11 893 575 646 457,63
7	test	RMSE	3 448 706,37
8	test	R2	0,62

Рисунок 7 – Результат регрессионной метрики для модели на Python Binary Encoder через тестовую выборку




Рисунок 8 – Диаграмма рассеяния для модели на Python Binary Encoder

Выходной набор данных			
#	ab Метрика	Значение	
1	r2	0,62	
2	explained_variance	0,66	
3	max_error	36 506 467,26	
4	mean_absolute_error	2 106 543,47	
5	mean_squared_log_error		
6	mean_squared_error	11 893 575 646 457,54	
7	median_absolute_error	1 293 228,14	
8	mean_absolute_percentage_error	0,21	
9	d2_absolute_error_score	0,41	

Рисунок 9 – Результат регрессионной метрики для модели на Python через кастомный энкодер для обучающей выборки




Рисунок 10 – Диаграмма рассеяния для модели на Python через кастомный энкодер для обучающей выборки

Модель линейной регрессии показала качество - коэффициент детерминации R^2 на тестовой выборке равен 0.62, а средняя ошибка 2.106.

По аналогии с двумя модулями через Logitom был собран вариант через XGBRegressor для линейной регрессии. На рисунке 11 показана схема модели через XGBRegressor. На 12-13 показаны ее метрики оценки качества регрессионной модели через тестовую выборку. На рисунках 14-15 показан результат через обучающую выборку.




Рисунок 11 – Схема для линейной регрессии XGBRegressor

Выходной набор данных			
#	ab Выборка	ab Метрика	9.0 Значение
1	train	MAE	819 098,45
2	train	MSE	2 231 146 062 576,24
3	train	RMSE	1 493 702,13
4	train	R2	0,91
5	test	MAE	1 665 186,89
6	test	MSE	6 733 529 123 476,67
7	test	RMSE	2 594 904,45
8	test	R2	0,78

Рисунок 12 – Результат регрессионной метрики для модели на XGBRegressor Ordinal Encoder через тестовую выборку




Рисунок 13 – Диаграмма рассеяния для модели на XGBRegressor Ordinal Encoder

Выходной набор данных		
#	ab Метрика	9.0 Значение
1	r2	0,78
2	explained_variance	0,82
3	max_error	31 174 972,00
4	mean_absolute_error	1 665 186,89
5	mean_squared_log_error	0,05
6	mean_squared_error	6 733 529 123 476,67
7	median_absolute_error	1 081 289,50
8	mean_absolute_percentage_error	0,17
9	d2_absolute_error_score	0,53

Рисунок 14 – Результат регрессионной метрики для модели на XGBRegressor через кастомный энкодер для обучающей выборки




Рисунок 15 – Диаграмма рассеяния для модели на XGBRegressor через кастомный энкодер для обучающей выборки

На основе оценок R^2 и диаграммы рассеяния, демонстрирующей существенно более полное совпадение предсказанных и фактических значений, из трёх ранее разработанных моделей наиболее точной следует признать **XGBRegressor** по сравнению с другими моделями из библиотеки Sklearn и из стандартного узла Loginom. Последние две модели предсказуемо дали практически одинаковые, хотя и не полностью совпадающие результаты; расхождения могут быть обусловлены отличиями в реализации либо разными значениями сида, заданными при обучении.

3.2 Регрессионный анализ с учетом временного изменения

На рисунке 16 представлен результат схемы для анализа набора ПОЛИКЛИНИК:




Рисунок 16 – Схема для анализа временного изменения

Выполнение задания показало: оптимальная модель - полиномиальная регрессия с 6 степенями. Дальнейшее повышение степени почти не увеличивает точность. Однако, судя по исходным данным и графику «факт — прогноз» (рисунок 17), эту модель нельзя считать достоверной. Ввиду особенностей линейной регрессии и **малого размера обучающей выборки** последующие прогнозы вряд ли будут успешными.

Выходной набор данных			
#	ab Имя	ab Метка	Значение
1	R2	Коэффициент детерминации	0,70
2	R2	Коэффициент детерминации	0,72
3	R2	Коэффициент детерминации	0,90
4	R2	Коэффициент детерминации	0,91
5	R2	Коэффициент детерминации	0,96
6	R2	Коэффициент детерминации	0,97

Рисунок 17 – Метрики




Рисунок 18 – Диаграмма соответствия прогноза им факта

3.3 Модель оценки склонности к приобретению

Для выполнения третьего задания для исследования построили модели логистической регрессии — одну на исходных табличных значениях, другую на тех же числах, но возведённых в квадрат. Категориальные признаки перевели в бинарный вид, создав под каждый отдельный столбец.

Лучшей признана модель без квадратичных признаков: при сопоставимом значении AUC она эффективнее идентифицирует потенциальных покупателей и проще для интерпретации. Следовательно, её можно использовать для оценки покупательской склонности клиентов.

Качество модели достаточно высокое: на тестовой выборке $AUC_ROC = 0,8062$ — это хорошая способность различать клиентов, склонных и не склонных к покупке. Близость метрик на обучении и тесте указывает на отсутствие заметного переобучения.

На рисунке 19 изображена схема для третьего задания.




Рисунок 19 – Модель оценки склонности к приобретению

Оценки классификации

Показатель	Множества	
	Обучающее	Тестовое
Оценки классификатора ^		
AUC ROC	0,8051	0,8062
AUC PR	0,6145	0,6156
Коэффициент Джини	0,6102	0,6125
KS	45,2474	45,2333
Порог отсечения: Из настроек узла ^		
Значение	0,5000	0,5000
TPR (Чувствительность)	0,5534	0,5509
TNR (Специфичность)	0,8748	0,8768
FPR (1-Специфичность)	0,1252	0,1232
PPV	0,5934	0,5963
F1 Score	0,5727	0,5727
MCC	0,4386	0,4395

Рисунок 20 – Оценки классификации