

ЛАБОРАТОРНАЯ РАБОТА 6

Линейная регрессия

Задача линейной регрессии заключается в нахождении коэффициентов уравнения **линейной регрессии**, которое имеет вид:

$$y = b_0 + b_1x_1 + b_2x_2 + \dots + b_nx_n$$
, где y — выходная (зависимая) переменная модели;
 $x_1, x_2, \dots, x_n$ — входные (независимые) переменные; b_i — коэффициенты линейной регрессии (b_0 — свободный член).

Задача линейной регрессии заключается в подборе коэффициентов b_i уравнения таким образом, чтобы на заданный входной вектор $\mathbf{X} = (x_1, x_2, \dots, x_n)^T$ регрессионная модель сформировала желаемое выходное значение y .

Одним из наиболее востребованных приложений линейной регрессии является прогнозирование. В этом случае входными переменными модели x_i являются наблюдения из прошлого (предикторы), а y — прогнозируемое значение.

Например, регрессионная модель для прогнозируемого параметра *Объем услуг* (столбец 3 на рис. 1) рассчитала коэффициенты линейной регрессии для трех входных параметров — рис. 2. Параметр «Число активных абонентов подвижной радиотелефонной связи, использующих широкополосный доступ к сети Интернет на 100 человек населения (x_4)» был исключен при отборе факторов как фактор с наименьшим приоритетом [1].

12 №	ab Регион	9.0 Объем ус...	9.0 Наличие квартирн...	9.0 Число подключен...	9.0 Число активных абонентов фикс...	9.0 Число активных абонентов подвижн...
1	Республика Баш...	3951	135,4	1737,9	20,2	71,5
2	Республика Мар...	4240,8	138,6	1846,6	17,2	70,3
3	Республика Мор...	4238,1	186,3	1590,6	17,9	58,9
4	Республика Тата...	5253,2	175,3	1850,8	24,5	73,9
5	Удмуртская Респ...	4161,9	117,5	1763,4	19,4	66,6
6	Чувашская Респ...	4014	117,5	1787,4	17,1	74,5
7	Пермский край	4514,7	176,9	1831,1	14,3	43,1
8	Кировская обла...	4764,7	187,3	1743,9	19,9	56,4
9	Нижегородская ...	5599,3	236,4	2017,5	24,8	70,7
10	Оренбургская о...	4506	192,6	1871,9	16,6	73,4
11	Пензенская обл...	4602,2	209,8	1636,5	18,6	68,5
12	Самарская обла...	5614,1	164,6	2034,6	20,2	82,2
13	Саратовская об...	4845,9	155,4	1798,3	19,8	70,7
14	Ульяновская об...	4509,5	170,6	1936,6	19,5	67,3

Рисунок 1 – Объемы оказанных услуг по регионам

Атрибут	Коэффициент
9.0 Константа	-1 407,059361
9.0 Наличие квартирных телефонных аппаратов сети общего пользования на 1000 человек населения (x_1)	6,723707
9.0 Число подключенных абонентских устройств подвижной радиотелефонной связи на 1000 человек населения (x_2)	1,999330
9.0 Число активных абонентов фиксированного широкополосного доступа к сети Интернет на 100 человек населения (x_3)	65,707027

Рисунок 2 – Коэффициенты линейной регрессии

Метрики и оценки: количественная оценка качества прогнозов

Насколько линейная аппроксимация соответствует наблюдаемым данным можно увидеть на вкладке **Сводка** штатного компонента Loginom *Линейная регрессия* (рис. 3).

R^2 – коэффициент детерминации, отражающий объясняющую способность регрессии, показывает, что на 78% расчетные параметры модели, то есть сама модель, объясняют зависимость и изменения изучаемого параметра **Y** от исследуемых факторов **X** .




Рисунок 3 – Метрики модели регрессии

В библиотеке ***loginom_sklearn_kit*** реализованы несколько компонентов для вычисления функции потерь. Например, компонент ***regression_metrics*** позволяет вычислить ряд параметров, в том числе сделать оценку абсолютной погрешности модели видно на рис.4.




Рисунок 4 – Оценка абсолютной погрешности модели

Интерпретация модели

Модель зависимости между входными и выходной переменными с линейной функцией связи для набора данных рис. 1 получилась следующая:

$$Y = -1407,059361 + 6,623707 \cdot X_1 + 1,999330 \cdot X_2 + 65,707027 \cdot X_3$$

В простой линейной регрессии коэффициент b_i интерпретируется как изменение значения выходной переменной при изменении входной переменной на единицу. Таким образом, изменение параметра «Наличие квартирных телефонных аппаратов сети общего пользования на 1000 человек население (x_1)» на 1, т.е. на 1000 аппаратов, может привести к увеличению объема оказанных услуг в 6 раз.

Нелинейные регрессионные модели

Линейная регрессионная модель не всегда пригодна для предсказания зависимой переменной. Между зависимой и независимыми переменными набора данных могут существовать **нелинейные соотношения**, которые выражаются соответствующими нелинейными функциями.

Рассмотрим пример данных *Заработная плата.xlsx* о заработной плате сотрудников и их возрасте. Требуется определить зависит ли заработная плата от возраста сотрудника.

В соответствии с диаграммой зависимости *Зарботной платы* от *Возраста* (рис.5) можно сделать предположение о том, что наблюдается параболическая зависимость заработной платы от возраста работающего. Такую зависимость можно отобразить с помощью модели квадратичной регрессии: $\hat{y} = b_0 + b_1x + b_2x^2$.

Произведем линейризацию нелинейной регрессионной модели путем замены x^2 новой переменной. Уравнение примет следующий вид: $\hat{y} = b_0 + b_1x_1 + b_2x_2$.




Рисунок 5 – Диаграмма зависимости *Зарботной платы* от *Возраста*

Добавим в набор данных новый столбец как на рис.6. Построим модель, используя компонент Logitom **Линейная регрессия**.

#	9.0 Возраст в квадрате	12 Табельный номер рабочего	9.0 Зарботная плата в месяц, руб.	9.0 Возраст, лет
1	484	32	41990	22
2	576	17	44840	24
3	625	70	47500	25
4	625	45	47500	25
5	676	26	47880	26
6	784	40	55309	28
7	841	47	52136	29
8	900	31	55670	30
9	1024	50	54150	32
10	1156	33	61009	34

Рисунок 6 – Добавление в набор новой переменной

Из полученного отчета по регрессии (рис.7) уравнение квадратичной регрессионной модели имеет вид: $\hat{y} = -73086,1 + 7570,6x - 109,6x^2$.

Коэффициент детерминации ***R*²** для модели равен 0,816616, что довольно близко к 1. При оценке регрессионных моделей это интерпретируется как соответствие модели данным.

Модель Финальная модель			
Показатель	Значение	Атрибут	Коэффициент
Константа	Включена	9.0 Константа	-73 086,100817
Логарифм функции правдоподобия	-146,663554	9.0 Возраст в квадрате	-109,608084
Коэффициент детерминации	0,816619	9.0 Возраст, лет	7 570,608240
Коэффициент детерминации (скорр.)	0,788407		
Стандартное отклонение	2 569,208848		
Число степеней свободы ошибки	13,00		
Число степеней свободы модели	2,000000		
F-статистика	28,945331		
P-значение модели	0,000016		
Критерий Акаике	18,707944		
Критерий Акаике (скорр.)	18,832944		
Критерий Байеса	18,852805		
Критерий Ханнана-Куинна	18,715362		

Рисунок 7 – Отчет по регрессии

Диаграмма зависимости *Зарботной платы* от *Возраста* представлена на рис.8. Максимальная заработная плата 61009 руб./месяц у сотрудников в возрасте 34 лет.




Рисунок 8 – Диаграмма зависимости заработной платы от возраста

Логистическая регрессия

При анализе данных часто встречаются задачи, где выходная переменная является *категориальной*. При организации связей между набором входных переменных и

категориальной выходной переменной получила распространение **логистическая регрессия** [2].

Оценка соответствия логистической регрессии реальным данным

Для оценки качества модели можно воспользоваться встроенными визуализаторами, например, **ROC-кривой**. Кривая показывает зависимость количества верно классифицированных примеров от количества неверно классифицированных примеров.

Анализ этой кривой помогает оценить качество модели классификации. Чем меньше расстояние от диагональной прямой до кривой, тем менее эффективна модель. Диагональ соответствует бесполезной модели классификации. Чем кривая ближе к верхнему левому углу, тем больше предсказательная способность модели.

Интерпретация модели

Коэффициенты в выходных данных модели представляют среднее изменение логарифмических шансов переменной ответа, связанной с увеличением на единицу переменной-предсказателя.

Задания для самостоятельной работы:

Задание 1

Скачайте набор данных по недвижимости России 2018-2021г. [3].

Для выполнения исследования используйте шаблон ***LinearReg_template.lgp***.

В шаблоне имеются как материалы для изучения, так и задания для самостоятельной работы. Например, освоите приемы создания новых признаков датасета в сценарии ***Подготовка данных***.

Выполните задания в проекте и сравните качество моделирования встроенного в Loginom компонента ***Линейная регрессия*** и моделей линейной регрессии Python (sklearn). Для запуска моделей Python используйте компонент ***model.fitter*** из ***loginom_sklearn_kit***.

В отчете представьте разработанные сценарии моделирования и ответы на тестовые вопросы. Напишите свои выводы по качеству моделей. Какую модель из трех исследованных вы в итоге выберете и почему?

Задание 2

В файле **Число амбулаторно-поликлинических организаций.xlsx** имеются данные о числе амбулаторно-поликлинических организаций в Российской Федерации за 19 лет. Выполните регрессионный анализ датасета с учетом временного изменения числа амбулаторно-поликлинических организаций.

Задание 3

В файле **Клиенты торговой сети.xlsx** приведены данные о клиентах торговой сети и их реакции на адресные предложения о приобретении новой линии продуктов. Информация о клиентах содержит такие данные: пол клиента; возрастная группа покупателя; статус скидочной карты (бронзовая, серебряная, золотая, платиновая); число месяцев с момента получения скидочной карты; общая сумма потраченных средств; сегмент совокупного семейного дохода покупателя. Результирующий признак – количество купленных товаров из группы новых товаров.

Требуется, используя 70% случайную выборку клиентов, создать модель для оценки склонности клиентов к приобретению продуктов новой линии. Выбросы и экстремальные значения оставить без изменения.

Источники:

1. Loginom/Loginom-help. URL: <https://github.com/loginom/loginom-help/blob/data/processors/datamining/linear-regression/README.md?ysclid=lgpahjvcbe603313643> (дата просмотра 28.03.26)
2. Loginom. Логистическая регрессия. URL: <https://help.loginom.ru/userguide/processors/datamining/logistic-regression/index.html> (дата просмотра 28.03.26)
3. Недвижимость России 2018-2021. URL: <https://www.kaggle.com/datasets/mrdaniilak/russia-real-estate-20182021> (дата посещения 28.03.2026)