

ГУАП

КАФЕДРА № 42

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ
ПРЕПОДАВАТЕЛЬ

доцент

должность, уч. степень,
звание

подпись, дата

Н.В. Богословская

инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №7

по курсу: Большие данные

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ гр. № 4321

подпись, дата

Г.В. Буренков

инициалы, фамилия

Санкт-Петербург 2026

1 Цель работы

Изучение методов оптимального квантования и биннинга данных.

2 Задание

1. Используя биннинг выполните оценку склонности клиента к положительному отклику по его признаковому описанию. Решите поставленную задачу несколькими способами: с IV отбором значимых признаков, с WoE-кодированием для замены значений признаков. Протестируйте полученные модели и обоснуйте выбор оптимального сценария.

2. Закончить сценарий: банк должен обратиться с предложением только к тем клиентам, у которых значение оценки выше некоторого порога. Сформируйте список клиентов для рассылки в виде отчета. Значение порога определите самостоятельно

3 Ход выполнения задания

В ходе выполнения данной лабораторной работы была составлена схема, представленная на рисунке 1.




Рисунок 1 – Схема Loginom

Как показано на рисунке 2, после четвёртого отбора (исключая поля TARGET и ID заявки) количество полей составило 29.

№	☒	Тип	Метка	Вид
0	☒	ab	AGREEMENT_RK	☼
1	☒	12	TARGET	☼
2	☒	ab	b2_Возраст_Сред...	☼
3	☒	ab	a9_Социальный ст...	☼
4	☒	ab	b4_Социальный с...	☼
5	☒	ab	c4_Кол-во ижде...	☼
6	☒	ab	a1_Работа - отрас...	☼
7	☒	ab	a5_Работа - должн...	☼
8	☒	ab	a2_Работа - форм...	☼
9	☒	ab	b1_Работа - Отн. к ...	☼
10	☒	ab	a8_Работа - напр-...	☼
11	☒	ab	b6_Семейный дох...	☼
12	☒	ab	b3_Личный доход ...	☼
13	☒	ab	a7_Область регис...	☼
14	☒	ab	a3_Область факт. ...	☼
15	☒	ab	a4_Почтовый адр...	☼
16	☒	ab	a6_Область торго...	☼
17	☒	ab	b5_Регион РФ_Ни...	☼
18	☒	ab	c5_Все адреса сов...	☼
19	☒	ab	c7_Последний кре...	☼
20	☒	ab	b8_Срок посл. кре...	☼
21	☒	ab	b7_Первонач. взн...	☼
22	☒	ab	c3_Кол-во месяце...	☼
23	☒	ab	a0_Стаж работы н...	☼
24	☒	ab	b0_Наличие раб. т...	☼
25	☒	ab	c6_Кол-во погаше...	☼
26	☒	ab	c1_Кол-во просро...	☼
27	☒	ab	c2_Номер максим...	☼
28	☒	ab	c0_Средняя сумма...	☼
29	☒	ab	b9_Максимальная...	☼

Рисунок 2 – Отбор 3: Столбцы

Согласно рисунку 3, при построении логистической регрессии непосредственно после IV-отбора (без применения WOE-кодирования) значение R^2 составило 0,11. Это низкий показатель, к тому же фактическое и прогнозное количество положительных откликов совпало лишь в 30 наблюдениях.

№	Имя	Метка	Значение
1	12 TotalSamples	Всего примеров	14 910
2	12 TotalSelectedSamples	Всего отобранных примеров	14 910
3	12 TrainSamples	Примеров в обучающем множестве	8 946
4	9.0 TrainRMSError	Среднеквадратическая ошибка на обучающем множестве	0,31
5	9.0 TrainClsErrorPercentage	Процент ошибок классификации на обучающем множестве	12,32
6	9.0 TrainAvgCE	Средняя перекрестная энтропия на обучающем множестве	0,48
7	9.0 TrainThreshold	Порог отсечения при обучении модели	0,50
8	9.0 NullMinusTwoLogL	-2 Логарифма функции правдоподобия нулевой модели	6 654,07
9	9.0 MinusTwoLogL	-2 Логарифма функции правдоподобия	5 945,80
10	9.0 R2	Псевдо-R ² Макфаддена	0,11
11	9.0 AdjustedR2	Псевдо-R ² Макфаддена (скорр.)	0,08
12	12 DFE	Число степеней свободы ошибки	8 866
13	12 ModelDF	Число степеней свободы модели	79
14	9.0 Chi2	Хи-квадрат	708,27
15	9.0 AIC	Информационный критерий Акаике	0,68
16	9.0 AICc	Информационный критерий Акаике скорректированный	0,68
17	9.0 BIC	Информационный критерий Байеса	0,75
18	9.0 HQC	Информационный критерий Ханнана-Куинна	0,70
19	9.0 ModelPValue	P-значение модели	7,62e-102
20	12 TestSamples	Примеров в тестовом множестве	5 964
21	9.0 TestRMSError	Среднеквадратическая ошибка на тестовом множестве	0,31
22	9.0 TestClsErrorPercentage	Процент ошибок классификации на тестовом множестве	11,23
23	9.0 TestAvgCE	Средняя перекрестная энтропия на тестовом множестве	0,47

Рисунок 3 – Сводка оценок модели

TARGET, Отклик[Прогноз • Быстрый просмотр]									
Соответствуют условию					Не соответствуют условию				
#	12 TARGET	12 TARGET[Прогноз]	9.0 Событие[Прогноз]	9.0 Вероятность события[Прогноз]	9.0 Событие[Факт]	ab a0_Стаж работы на посл. месте (мес.)_Средняя	ab a2_Возраст_Средняя	ab b4_Социальный статус 1_Низ	
1	1	1	true	0,50	true	1 s...< 22	32 s...< 44	[работает]	
2	1	1	true	0,53	true	22 s...< 80	32 s...< 44	[работает]	
3	1	1	true	0,51	true	1 s...< 22	32 s...< 44	[работает]	
4	1	1	true	0,55	true	22 s...< 80	32 s...< 44	[работает]	
5	1	1	true	0,60	true	1 s...< 22	до 30	[работает]	
6	1	1	true	0,58	true	22 s...< 80	32 s...< 44	[работает]	
7	1	1	true	0,53	true	22 s...< 80	до 30	[работает]	
8	1	1	true	0,56	true	1 s...< 22	32 s...< 44	[работает]	
9	1	1	true	0,61	true	22 s...< 80	32 s...< 44	[работает]	
10	1	1	true	0,63	true	22 s...< 80	32 s...< 44	[работает]	
11	1	1	true	0,52	true	1 s...< 22	32 s...< 44	[работает]	
12	1	1	true	0,50	true	1 s...< 22	от 56	[работает]	
13	1	1	true	0,57	true	1 s...< 22	32 s...< 44	[работает]	
14	1	1	true	0,59	true	1 s...< 22	до 30	[работает]	
15	1	1	true	0,62	true	80 s...< 130	32 s...< 44	[работает]	
16	1	1	true	0,53	true	1 s...< 22	44 s...< 56	[работает]	
17	1	1	true	0,60	true	22 s...< 80	до 30	[работает]	
18	1	1	true	0,59	true	1 s...< 22	44 s...< 56	[работает]	
19	1	1	true	0,58	true	1 s...< 22	44 s...< 56	[работает]	
20	1	1	true	0,52	true	1 s...< 22	32 s...< 44	[работает]	
21	1	1	true	0,70	true	1 s...< 22	до 30	[работает]	
22	1	1	true	0,53	true	1 s...< 22	до 30	[работает]	
23	1	1	true	0,51	true	1 s...< 22	до 30	[работает]	
24	1	1	true	0,50	true	22 s...< 80	32 s...< 44	[работает]	
25	1	1	true	0,57	true	1 s...< 22	32 s...< 44	[работает]	
26	1	1	true	0,59	true	22 s...< 80	32 s...< 44	[работает]	
27	1	1	true	0,59	true	22 s...< 80	до 30	[работает]	
28	1	1	true	0,52	true	22 s...< 80	до 30	[работает]	
29	1	1	true	0,79	true	22 s...< 80	до 30	[работает]	
30	1	1	true	0,57	true	22 s...< 80	32 s...< 44	[работает]	

Рисунок 3.1 – Отчет привлекательных клиентов для банка (0.5 вероятность)

Согласно рисунку 4, в случае применения WOE-кодирования точность модели составила 0,09. Этот показатель ниже, при этом совпадение

фактических и спрогнозированных положительных откликов зафиксировано всего в 13 случаях.

Выход регрессии		Коэффициенты регрессионной модели	Сводка	
№	Имя	Метка	Значение	
1	12 TotalSamples	Всего примеров	14 910	
2	12 TotalSelectedSamples	Всего отобранных примеров	14 910	
3	12 TrainSamples	Примеров в обучающем множестве	8 946	
4	9.0 TrainRMSError	Среднеквадратическая ошибка на обучающем множестве	0,32	
5	9.0 TrainClsErrorPercentage	Процент ошибок классификации на обучающем множестве	12,21	
6	9.0 TrainAvgCE	Средняя перекрестная энтропия на обучающем множестве	0,48	
7	9.0 TrainThreshold	Порог отсеивания при обучении модели	0,50	
8	9.0 NullMinusTwoLogL	-2 Логарифма функции правдоподобия нулевой модели	6 598,74	
9	9.0 MinusTwoLogL	-2 Логарифма функции правдоподобия	6 014,78	
10	9.0 R2	Псевдо-R ² Макфаддена	0,09	
11	9.0 AdjustedR2	Псевдо-R ² Макфаддена (скорр.)	0,08	
12	12 DFE	Число степеней свободы ошибки	8 917	
13	12 ModelDF	Число степеней свободы модели	28	
14	9.0 Chi2	Хи-квадрат	583,96	
15	9.0 AIC	Информационный критерий Акаике	0,68	
16	9.0 AICc	Информационный критерий Акаике скорректированный	0,68	
17	9.0 BIC	Информационный критерий Байеса	0,70	
18	9.0 HQC	Информационный критерий Ханнана-Куинна	0,69	
19	9.0 ModelPValue	P-значение модели	2,95e-105	
20	12 TestSamples	Примеров в тестовом множестве	5 964	
21	9.0 TestRMSError	Среднеквадратическая ошибка на тестовом множестве	0,31	
22	9.0 TestClsErrorPercentage	Процент ошибок классификации на тестовом множестве	11,22	
23	9.0 TestAvgCE	Средняя перекрестная энтропия на тестовом множестве	0,47	

Рисунок 4 – Сводка оценок модели

TARGET, TARGET Прогноз • Быстрый просмотр									
Соответствуют условию					Не соответствуют условию				
#	12 TARGET	12 TARGET Прогноз	9.1 Событие Прогноз	9.0 Вероятность события Прогноз	0.1 Событие Факт	9.9 AGE_ClassMark	9.9 SOCSTATUS_WORK_FL_ClassMark	9.9 SOCSTATUS_PENS_FL_ClassMark	
1	1	1	true	0,53	true	0,20	0,09	0,10	
2	1	1	true	0,53	true	0,20	0,09	0,10	
3	1	1	true	0,62	true	0,30	0,09	0,10	
4	1	1	true	0,56	true	0,20	0,09	0,10	
5	1	1	true	0,54	true	-0,24	0,09	0,10	
6	1	1	true	0,53	true	-0,24	0,09	0,10	
7	1	1	true	0,52	true	-0,24	0,09	0,10	
8	1	1	true	0,64	true	0,30	0,09	0,10	
9	1	1	true	0,53	true	0,20	0,09	0,10	
10	1	1	true	0,56	true	0,20	0,09	0,10	
11	1	1	true	0,51	true	0,30	0,09	0,10	
12	1	1	true	0,58	true	0,20	0,09	0,10	
13	1	1	true	0,52	true	0,20	0,09	0,10	

Рисунок 4.1 – Отчет привлекательных клиентов для банка (0.5 вероятность)

Если не использовать конечные классы и WOE-кодирование, а выполнить логистическую регрессию сразу на исходном наборе данных, то точность модели составит 0,12 (см. рисунок 5). При этом фактические и прогнозные положительные отклики совпали в 73 случаях.

Выход регрессии		Коэффициенты регрессионной модели		Сводка	
№	Имя	Метка	Значение		
1	12 TotalSamples	Всего примеров	14 910		
2	12 TotalSelectedSamples	Всего отобранных примеров	14 910		
3	12 TrainSamples	Примеров в обучающем множестве	8 946		
4	9.0 TrainRMSError	Среднеквадратическая ошибка на обучающем множестве	0,30		
5	9.0 TrainClsErrorPercentage	Процент ошибок классификации на обучающем множестве	11,37		
6	9.0 TrainAvgCE	Средняя перекрестная энтропия на обучающем множестве	0,45		
7	9.0 TrainThreshold	Порог отсечения при обучении модели	0,50		
8	9.0 NullMinusTwoLogL	-2 Логарифма функции правдоподобия нулевой модели	6 414,00		
9	9.0 MinusTwoLogL	-2 Логарифма функции правдоподобия	5 623,70		
10	9.0 R2	Псевдо-R ² Макфаддена	0,12		
11	9.0 AdjustedR2	Псевдо-R ² Макфаддена (скорр.)	-0,01		
12	12 DFE	Число степеней свободы ошибки	8 513		
13	12 ModelDF	Число степеней свободы модели	432		
14	9.0 Chi2	Хи-квадрат	790,30		
15	9.0 AIC	Информационный критерий Акаике	0,73		
16	9.0 AICc	Информационный критерий Акаике скорректированный	0,73		
17	9.0 BIC	Информационный критерий Байеса	1,07		
18	9.0 HQC	Информационный критерий Ханнана-Куинна	0,84		
19	9.0 ModelPValue	P-значение модели	2,31e-23		
20	12 TestSamples	Примеров в тестовом множестве	5 964		
21	9.0 TestRMSError	Среднеквадратическая ошибка на тестовом множестве	0,32		
22	9.0 TestClsErrorPercentage	Процент ошибок классификации на тестовом множестве	12,51		
23	9.0 TestAvgCE	Средняя перекрестная энтропия на тестовом множестве	0,55		

Рисунок 5 – Сводка оценок модели

Соответствуют условию		Не соответствуют условию														
#	12 TARGET	12 TARGET Прогноз	9.0 Событие Прогноз	9.0 Вероятность события Прогноз	9.0 Событие Факт	ab	Идентификатор клиента	12 Возраст	12 Пол	12 Кол-во детей	12 Кол-во иждивенцев	9.0 Личный				
1	1	1	1	true	0,58	true	59913524	39	1	2		2				
2	1	1	1	true	0,63	true	59969137	41	0	1		1				
3	1	1	1	true	0,60	true	60101892	43	0	1		1				
4	1	1	1	true	0,63	true	60188414	40	0	2		2				
5	1	1	1	true	0,66	true	60376965	29	1	1		1				
6	1	1	1	true	0,53	true	60469119	36	1	3		3				
7	1	1	1	true	0,50	true	61102413	27	0	0		0				
8	1	1	1	true	0,53	true	61148433	31	1	1		1				
9	1	1	1	true	0,61	true	61152400	47	0	2		1				
10	1	1	1	true	1,00	true	61165832	48	0	1		1				
11	1	1	1	true	1,00	true	61248745	36	1	2		2				
12	1	1	1	true	0,99	true	61306993	33	1	0		0				
13	1	1	1	true	1,00	true	61307578	28	0	0		0				
14	1	1	1	true	1,00	true	61355847	34	1	2		1				
15	1	1	1	true	0,55	true	61433612	52	1	1		1				
16	1	1	1	true	0,68	true	61448855	41	1	0		0				
17	1	1	1	true	1,00	true	61470498	44	0	3		3				
18	1	1	1	true	0,50	true	61540371	42	1	1		1				
19	1	1	1	true	0,53	true	61850600	51	1	1		0				
20	1	1	1	true	1,00	true	61930360	40	0	2		2				
21	1	1	1	true	1,00	true	62092540	40	0	1		1				
22	1	1	1	true	1,00	true	62235129	47	1	3		1				
23	1	1	1	true	1,00	true	62238532	35	0	1		1				
24	1	1	1	true	0,51	true	62252057	28	1	1		1				
25	1	1	1	true	0,50	true	62365747	37	0	1		1				
26	1	1	1	true	1,00	true	62427886	58	1	0		0				
27	1	1	1	true	1,00	true	62442225	48	0	3		1				
28	1	1	1	true	0,97	true	62617233	54	1	0		0				
29	1	1	1	true	0,52	true	63319835	41	1	3		2				
73	1	1	1	true	0,68	true	63326630	29	1	2		2				

Рисунок 5.1 – Отчет привлекательных клиентов для банка (0.5 вероятность)