

ЛАБОРАТОРНАЯ РАБОТА 7

В лабораторной работе будет изучен эффективный инструмент разведочного анализа, который пришел в аналитику данных из кредитного скоринга - **оптимальное квантование и биннинг данных**.

Применение инструмента:

- Оценка предсказательной силы отдельной переменной на выходное поле;
- Оценка силы и характера влияния отдельного бина на событие;
- Борьба с пропусками, выбросами и экстремальными значениями;
- Сокращение разнообразия уникальных значений в переменной;
- Эффективное использование логистической регрессии.

Компоненты Loginom Silver Kit

Библиотека готовых компонентов **Loginom Silver Kit** облегчает рутинный труд аналитика по разработке сценариев для автоматизированной обработки данных. Компонент библиотеки Loginom Silver Kit **Конечные классы** преобразует входные столбцы в последовательность интервалов, называемых конечными классами, каждому из которых присваивается определенная метка. Компонент применяется для:

- сокращения размерности данных,
- восстановления пропусков,
- борьбы с выбросами и экстремальными значениями,
- упрощения описания исследуемых объектов.

Для каждого входного столбца может быть вычислен **IV индекс** (Information Value - уровень значимости) для последующего отбора переменных в модели бинарной классификации.

Величина, определяющая значимость переменной в модели бинарной классификации, вычисляется на основе коэффициентов **WoE** (Weight of Evidence - вес доказательства).

$$IV = \sum_{i=1}^k \left\{ \left(\frac{N_i}{N} - \frac{P_i}{P} \right) * WoE_i \right\}$$

Информационный индекс всегда является положительной величиной. На основе **IV** определяется значимость признака по следующей методике:

- $IV < 0,02$ — значимость отсутствует;
- $0,02 \leq IV < 0,1$ — низкая значимость;
- $0,1 \leq IV < 0,3$ — средняя значимость;

- $IV \geq 0,3$ — высокая значимость.

Коэффициенты **WoE** и вычисленные на их основе значения **IV** являются критериями для формирования конечных классов оптимальным образом:

- максимизируя значимость признака в бинарной классификационной модели;
- максимизируя равномерность заполнения интервалов, что обеспечивает наилучшую репрезентативность результатов;
- используя компромисс между этими вариантами.

Компонент **IV-отбор** предназначен для постобработки результатов компонента **Конечные классы**:

- отбор столбцов, которые содержат метку конечного класса;
- отбор значимых столбцов.

На рис.1 приведен сценарий использования компонентов **Конечные классы** и **IV-отбор** из библиотеки Loginom Silver Kit.




Рисунок 1 – Сценарий сокращения размерности данных

В результате, каждое исходное значение признака было заменено на метку интервала квантования, а также выявлены и исключены из итоговой выборки незначимые признаки (рис.2).

Рисунок 2 – Результат применения Конечных классов

WoE-кодирование предполагает использование вместо меток или индексов для бинов их **WoE**-значений. Это наиболее эффективная схема кодирования, так как после ее применения все столбцы, подаваемые на вход **ML** (Machine Learning)-модели (как правило, это логистическая регрессия), будут вещественными. Новые, неизвестные значения, можно обрабатывать. Самое простое - присвоить им полную неопределенность, то есть **WoE** = 0.




Рисунок 3 – WoE-кодирование для замены меток бинов их WoE-значениями

На рис.3 сценарий сокращения размерности данных дополнен WoE-кодированием признаков. WoE-коды можно получить из выходных данных узла **Конечные классы** или использовать специализированный компонент из Loginom_Silver_Kit **Woe Encoder**.

Рис.4 — использование полученных WoE-кодированием признаков для тестовой выборке при выполнении логистической регрессии.




Рисунок 4 – Тестирование WoE-кодирования для логистической регрессии

Задание для самостоятельной работы

В качестве кейса для знакомства с работой биннинга с учителем предлагается использовать набор данных с конкурса «Задача предсказания отклика клиентов ОТП-банка». Задача предсказания отклика клиентов ОТП Банка — конкурс по решению прикладной задачи из области банковского маркетинга, проводимый в рамках всероссийской конференции «Математические методы распознавания образов» ММРО-15, г.Петрозаводск, Республика Карелия, 11–17 сентября 2011.

Описание задачи. Один из способов повышения эффективности взаимодействия банка с клиентами заключается в том, чтобы отправлять предложение о новой услуге не всем

клиентам банка, а только некоторой части, выбираемой по принципу наибольшей склонности к отклику на данное предложение.

Конкурсное задание заключалось в том, чтобы предложить алгоритм, который будет выдавать оценку склонности клиента к положительному отклику по его признаковому описанию. Эта оценка может (хотя и не обязана) интерпретироваться как вероятность положительного отклика. Предполагается, что, получив такие оценки для некоторого множества клиентов, банк обратится с предложением только к тем клиентам, у которых значение оценки выше некоторого порога.

Описание данных. Исходная выборка («выборка А») содержит записи о 15 223 клиентах, классифицированных на два класса: 1 — отклик был (1812 клиентов); 0 — отклика не было (13411 клиентов). Ещё 14 910 записей отложены в качестве тестовых («выборка Б»).

Записи (признаковые описания) клиентов состоят из 50 признаков, в состав которых входят, в частности, возраст, пол, социальный статус относительно работы, социальный статус относительно пенсии, количество детей, количество иждивенцев, образование, семейное положение, отрасль работы.

Данные доступны по следующим адресам:

выборка А для построения модели:

www.machinelearning.ru/wiki/images/2/26/Contest_MMRO15_OTP.rar

выборка Б для тестирования модели:

[www.machinelearning.ru/wiki/images/5/52/Contest_MMRO15_OTP_\(validation\).rar](http://www.machinelearning.ru/wiki/images/5/52/Contest_MMRO15_OTP_(validation).rar)

Обучающая и тестовые выборки в формате lgd: otp_train.lgd и otp_test.lgd.

Используя биннинг выполните оценку склонности клиента к положительному отклику по его признаковому описанию. Решите поставленную задачу несколькими способами: с IV-отбором значимых признаков, с WoE-кодированием для замены значений признаков. Протестируйте полученные модели и обоснуйте выбор оптимального сценария.

Закончите сценарий: банк должен обратиться с предложением только к тем клиентам, у которых значение оценки выше некоторого порога. Сформируйте список клиентов для рассылки в виде отчета. Значение порога определите самостоятельно.

Источники:

1. [Задача предсказания отклика клиентов ОТП Банка \(конкурс\) \(machinelearning.ru\)](http://www.machinelearning.ru) (дата посещения 10.04.26)