

ЛАБОРАТОРНАЯ РАБОТА 8. ОБНАРУЖЕНИЕ АНОМАЛИЙ. АЛГОРИТМ LOF

Лабораторная работа знакомит с популярным алгоритмом поиска аномалий в наборах данных — **Local Outlier Factor (LOF)**, в основе которого лежит концепция поиска ближайшего соседа [1].

Задача обнаружения аномалий актуальна при подготовке и очистке датасетов и построении моделей в отсутствии наблюдения события (например, диагностика поломок оборудования).

Выбросы и аномалии

Выброс (англ. исключение) — результат измерения, выделяющийся из общей выборки.

Аномалия (англ.: аномалии) — часто синоним выброса, но ряд исследователей разделяют эти понятия.

Будем считать, что методы обнаружения аномалий способны обнаружить как редкие наблюдения – выбросы, так и необычное поведение в данных.

Причины появления аномалий в данных:

1. Ошибки измерений и регистрации данных.
2. Загрязнение данных, например, некорректный отбор.
3. Воздействие случайных, не поддающихся прогнозированию факторов, например, поломка датчика, форс-мажор.
4. Целенаправленные действия, например, мошенническая активность.

Необходимость обнаружения выбросов:

1. Разведочный анализ данных — понимание причин явлений.
2. Для моделирования — выбросы могут ухудшать качество моделей.
3. Самостоятельная задача — для классификации новых наблюдений на нормальные и аномальные.

Типы аномалий:

- Точечная или глобальная (POINT, глобальный).
- Контекстная или условная (contextual).
- Коллективная (коллектив).

Точечная (глобальная аномалия) — отдельные значения, которые сильно отклоняются от ожидаемых значений. Пример: возраст клиента 150 лет; температура воздуха -70°C ; площадь жилой комнаты 2 м^2 .

Контекстная аномалия — наблюдения, которые являются аномалиями только в определенном контексте или подмножестве данных. Примеры: внезапный рост спроса на товар; ночной рост энергопотребления офисного здания; 28°C является выбросом для питерской зимы, но не является выбросом в другом контексте.

Коллективная аномалия возникает, когда последовательность связанных экземпляров данных (например, участок временного ряда) является аномальной по отношению к остальным данным. Примеры: аритмия на ЭКГ, большой набор транзакций одной и той же акции среди небольшой стороны за короткий период.

Автоматические методы обнаружения выбросов: обучение без учителя, обучение частично с учителем, обучение с учителем.

Задачи, связанные с поиском аномалий: обнаружение аномалий, обнаружение новизны.

Алгоритм LOF — коэффициент локального выброса (Local Outlier Factor)

Основная идея алгоритма LOF: у аномалии соседей мало, а у типичного наблюдения — много (локальная плотность). Алгоритм использует какую-либо метрику для подсчета расстояния. Понятия алгоритма LOF:

- k-дистанция, k-соседи;
- Доступность расстояния (RD), Достижимое расстояние;
- Локальная плотность доступности (LRD), Локальная плотность достижимости;
- Локальный фактор исключения (LOF), Локальный уровень выброса.

В Python-библиотеке scikit-learn реализация алгоритма LOF доступна в модуле Neighbors [3]. Необходимые универсальные компоненты представлены на рис.1, на рис. 2 показаны готовые компоненты библиотеки для построения модели LOF.

Для расчета метрик качества построенной модели можно использовать компонент classification metrics (рис.3) из библиотеки loginom_sklearn_kit. Компонент имеет входные параметры, значения которых необходимо установить [3].




Рисунок 1 – Универсальные компоненты




Рисунок 2 – Мета-компоненты для модели LOF




Рисунок 3 – Компонент classification metrics

Требования к отчету:

В качестве самостоятельного задания компания Loginom предлагает поработать с реальным датасетом из медицины и построить модель поиска аномалий алгоритмом LOF; применить модель на тестовом множестве и оценить ее качество.

ECG5000 – набор данных для выполнения самостоятельного задания содержит 141 столбец и 5000 записей. Из них 140 столбцов – показатели, описывающие деятельность сердечного ритма, и один столбец – метка класса.

Всего 5 меток классов. Значение «1» представляет нормальный сердечный ритм, в то время как значения «2», «3», «4», «5» отражают различные отклонения.

Датасет был сформирован на основе регистрации показаний электрокардиограммы (ЭКГ) – линейного графика с пиками и впадинами, поэтому задача классификации показаний как нормальных или аномальных представляет собой задачу распознавания образов, хорошо подходящую для машинного обучения.

Датасет уже разбит на обучающий и тестовый наборы, 500 и 4500 записей соответственно.

Для задачи обнаружения аномалий набор данных был подвергнут дополнительной предобработке. Был удален класс «2», который обозначает пограничное состояние сердечной деятельности. В итоге осталось 3233 записей. Доля аномальных записей составила 9,71%.

Конечный набор данных представлен двумя файлами: **ecg_train.txt** (обучающий набор) и **ecg_test.txt** (тестовый набор).

На датасете ECG5000 требуется построить модель на базе алгоритма *LOF* для задачи выявления аномальных показаний сердечной деятельности.

- 1) Для модели *Local Outlier Factor (LOF)* нужно подобрать оптимальные параметры числа соседей *k* и коэффициента загрязненности *c*.
- 2) Для оценки качества модели требуется рассчитать метрику **F1**.
- 3) Построенная модель *LOF* может применяться для скоринга новых объектов.

Параметр *Число соседей k* нужно выбрать из следующих вариантов: 15, 20, 25.

Параметр *Коэффициент загрязненности c* нужно выбрать из следующих вариантов: 0.02, 0.05.

Подготовка данных

Откройте шаблон сценария и перейдите в модуль **Подготовка выборок**.

В первом, желтом блоке, объединяются два датасета в один, всего 3233 записей. Мы будем считать это нашим начальным общим набором данных.

Для того, чтобы построить модель классификации аномального сердечного ритма, нам необходимо сформировать три выборки заново:

- обучающая (**train**) – записи, на которых мы будем обучать (строить) модель;
- валидационная (**valid**) – на основе нее мы будем подбирать оптимальные параметры алгоритма *LOF* – Число соседей *k* и Коэффициент загрязненности *c*.
- тестовая (**test**) – записи, на которых мы будем оценивать итоговое качество модели.

Для обеспечения работы модели *LOF* в режиме скоринга новых объектов необходимо обучать ее с включенным параметром **Novelty=true**, чтобы решать задачу обнаружения новизны. Поэтому в обучающей выборке не должно быть аномальных записей. Кроме того, для идентификации записей нам потребуется столбец с уникальными значениями.

Эти действия выполняет блок сценария, который состоит из двух узлов (см. зеленый блок в сценарии).

Примем, что объемы наших трех выборок будут соотноситься в пропорции **70:15:15**.

В следующих двух блоках вам потребуется написать обработку, которая даст объединенный датасет с новыми столбцами **SAMPLE** и **IsTestSet**.

В первый столбец **SAMPLE** строкового типа мы запишем принадлежность записи к одной из трех выборок: train, valid, test. При этом:

- в выборке train содержится 70% от всех нормальных записей;
- все оставшиеся записи случайным образом делятся поровну на два класса valid и test с одинаковым соотношением классов по полю **CLASS**.

Второй столбец **IsTestSet** логического типа будет принимать **FALSE**, если запись принадлежит к выборке train и **TRUE** во всех остальных случаях. Это облегчит использование готовых компонентов из библиотеки Loginom Python Kits.

Для написания сценария вам потребуется компонент **Разбиение на множества**. Для воспроизводимости результатов, которые будут контролироваться преподавателем, используйте **Random seed=42**.

Построение модели

Требуется построить модель на базе алгоритма *LOF* для задачи выявления аномальных показаний сердечной деятельности.

- 1) Для этого используйте только «чистую» выборку – train.
- 2) Все остальные записи «прогоняют» через эту модель.
- 3) Фиксируйте метрики F1 и Fbeta на валидационной выборке (SAMPLE=valid) для различных значений параметров k и c. Для Fbeta предполагайте, что пропуск аномалии (FN) важнее ложного обнаружения (FP) в 4 раза.
- 4) Выберите ту модель, которая дает максимум метрики **Fbeta**.
- 5) Окончательную модель «прогоните» через тестовую выборку (SAMPLE=test) и также оцените метрику **F1**.

Параметр n_neighbors (*Число соседей*) **k** нужно выбрать из следующих вариантов: 15, 20, 25.

Параметр contamination (*Коэффициент загрязненности*) **c** нужно выбрать из следующих вариантов: 0.02, 0.05.

Если метрика одинаковая для различных моделей, то выберите ту, которая проще, то есть имеет меньшее значение числа соседей **k**.

Для нормализации выборок используйте мета-компонент **Meta-scaling**.

Для построения модели используйте компоненты **Neighbors.LOF Novelty** и **model.fitter**.

Для расчета метрик качества **Precision** (Точность), **Recall** (Полнота), **F1-score**, **Fbeta_score** и значений матрицы классификаций **TN**, **TP**, **FP**, **FN** используйте компонент **classification metrics** [4].

Этот компонент принимает на вход набор данных из двух полей: y_true (фактический класс) и y_pred (предсказанный класс). Они должны быть целого типа.

У компонента есть список переменных:

- Параметр **average** необходим для многоклассовых целей. В нашем случае – binary.
- Переменная **pos_label** отвечает за метку положительного класса. В нашем случае это аномалия. Рекомендуем оставлять ее по умолчанию равной 1, а после работы алгоритма **LOF** заменой произвести преобразования {-1 ->1} и {1->0}.
- Переменная **beta** – это коэффициент в формуле для вычисления метрики Fbeta_score. Коэффициент позволяет управлять приоритетом метрик точности (precision) и полноты (recall).

Если стоимости метрик одинаково важны, то **beta=1.0**.

Если **$\beta < 1$** , то значение метрики точность (precision) приоритетнее полноты (recall) или ошибка ложного обнаружения (FP) выше пропуска аномалии (FN).

Если **$\beta > 1$** , то значение метрики полнота (recall) приоритетнее точности (precision) или ошибка пропуска аномалии (FN) важнее ложного обнаружения (FP).

Источники:

1. Loginom/ Метрики качества моделей бинарной классификации. URL: <https://loginom.ru/blog/classification-quality?ysclid=moe3934wqa356514646> (дата посещения 25.04.26)
2. Scikit-learn. Машинное обучение на Python. Neighbors. URL: <https://scikit-learn.org/stable/modules/neighbors.html> (дата посещения 25.04.26)
3. Scikit-learn. Машинное обучение на Python. Metrics and scoring: quantifying the quality of predictions. URL: https://scikit-learn.org/stable/modules/model_evaluation.html (дата посещения 25.04.26)
4. Scikit-learn. sklearn.metrics. URL: <https://scikit-learn.org/stable/api/sklearn.metrics.html> (дата посещения 25.04.26)