

ГУАП

КАФЕДРА № 42

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ
ПРЕПОДАВАТЕЛЬ

доцент, канд. техн. наук
должность, уч. степень, звание

подпись, дата

В.А. Миклуш
инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №1

Вычисление статистических
характеристик текстовой информации

по курсу: Теория информации, данные,
знания

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ гр. №

4321

подпись, дата

Г.В. Буренков
инициалы, фамилия

Санкт-Петербург 2025

СОДЕРЖАНИЕ

1 Цель работы	2
2 Задание и исходные данные	3
3 Расчет информации	4
4 Построение и сравнение таблицы распределения частот.....	5
5 Вывод.....	7

1 Цель работы

Целью данной лабораторной работы является анализ текстовой информации, а также применение статистики для анализа текстов.

2 Задание и исходные данные

В ходе выполнения работы необходимо решить следующие задачи:

1. Определить количество информации (по Хартли), содержащееся в заданном сообщении, таблица 1;

Таблица 1 Исходные данные

№ п/п	Алфавит	Текст
1.	Русский	Не заглядывай вперёд, как Бог приведёт. Бог – то не Афонька Что с возу упало – то пропало. Бабу с воза, кобыле легче Здоровый бедняк счастливей больного миллионера

2. Построить таблицу распределения частот символов, характерных для заданного сообщения. Производится так называемая частотная селекция, текст сообщения анализируется как поток символов и высчитывается частота встречаемости каждого символа. И сравнить с имеющимися данными в таблице 2.

Таблица 2 – Частота знаков алфавита для русского языка

Буквы	Частота букв	Буквы	Частота букв	Буквы	Частота букв
пробел	0,145	к	0,029	ч	0,013
о	0,095	м	0,026	й	0,001
е	0,074	д	0,026	х	0,009
а	0,064	п	0,024	ж	0,008
и	0,064	у	0,021	ю	0,007
т	0,056	я	0,019	ш	0,006
н	0,056	ы	0,016	ц	0,004
с	0,047	з	0,015	щ	0,003
р	0,041	ь,ъ	0,015	э	0,003
в	0,039	б	0,015	ф	0,002
л	0,036	г	0,014		

3. На основании полученных данных определить среднее и полное количество информации, содержащееся в заданном сообщении; Также необходимо оценить избыточность сообщения.

3 Расчет информации

Для расчета информации воспользуемся формулой Хартли $I = \text{Log}_2(M^n)$, где M – размер алфавита, n – длина сообщения.

$$I = \text{Log}_2(34^{155}) = 155 \cdot 4.643856 = 719.80 \text{ бита}$$

Для получения более обширной информации воспользуемся Энтропией Шеннона (среднее количество информации на символ):

$H = - \sum (p_i \cdot \text{Log}_2 p_i)$, и используем результат для получения общего количество информации по Шеннону:

$$I = L \cdot N = 155 \cdot 4.229364 = 655.55 \text{ бит}$$

Избыточность вычисляется по формуле $R = 1 - (H / H_0)$, где $H_0 = \text{Log}_2(n)$
 $H_0 = 4.643856 \text{ бит/символ}$, а $R = 1 - 4.229364 / 4.643856 = 8.93\%$

4 Построение и сравнение таблицы распределения частот

В данном разделе построим таблицу распределения. В таблице 1 представлена таблица распределения частот символов в тексте.

Таблица 1 – Распределение частот символов в тексте

Символ	Кол-во	Частота (доля)	Частота (%)
(пробел)	25	0.1613	16.13%
о	18	0.1161	11.61%
е	12	0.0774	7.74%
а	11	0.071	7.10%
л	9	0.0581	5.81%
в	7	0.0452	4.52%
б	7	0.0452	4.52%
н	6	0.0387	3.87%
г	5	0.0323	3.23%
д	5	0.0323	3.23%
п	5	0.0323	3.23%
р	5	0.0323	3.23%
к	5	0.0323	3.23%
т	5	0.0323	3.23%
з	4	0.0258	2.58%
и	4	0.0258	2.58%
с	4	0.0258	2.58%
ы	3	0.0194	1.94%
й	3	0.0194	1.94%
ч	3	0.0194	1.94%
у	3	0.0194	1.94%
я	2	0.0129	1.29%
ь	2	0.0129	1.29%
ф	1	0.0065	0.65%
м	1	0.0065	0.65%

Для наглядности приведу гистограмму сравнения усредненных частот для русского языка таблицы 1 и таблицы 2. На рисунке 1 изображена гистограмма частот.




Рисунок 1 – Гистограмма частот символов в русском языке

В таблице 2 даются усреднённые частоты для русского языка: пробел часто (14.5%), буква «о» (9.5%), «е» (7.4%), «а» (6.4%) и так далее. На наших данных (короткий набор пословиц): пробел оказался ~16.1% — немного выше табличного (в небольшом тексте это нормально); «о» — 11.6% (таблица ~9.5%) — в наших пословицах «о» встречается чаще, поэтому сдвиг вверх; «е», «а» — в порядке ожидаемости («е» $\approx 7.7\%$, «а» $\approx 7.1\%$) — близко к табличным значениям. Мелкие расхождения естественны: выборка мала (всего 155 символов), текст тематически ограничен (пословицы), поэтому частоты заметно отклоняются от долгосрочных средних по языку. Таким образом, направление распределения совпадает (пробел и «о», «е», «а» — самые частые), но величины процентных частот колеблются из-за малого объёма и жанровой специфики.

5 Вывод

В ходе выполнения лабораторной работы был произведён анализ текстовой информации на основе заданного сообщения. Определено количество информации по Хартли (719,80 бит) и по энтропии Шеннона (655,55 бит). Рассчитана избыточность текста, которая составила около 8,93%, что свидетельствует о наличии статистической избыточности, характерной для естественного языка.

Также была построена таблица распределения частот символов. Сравнение полученных данных с усреднёнными частотами для русского языка показало совпадение в распределении по наиболее употребительным символам («пробел», «о», «е», «а»), при этом выявлены незначительные расхождения в величинах, обусловленные малым объёмом выборки и спецификой исследуемого текста.

Таким образом, цель работы достигнута: проведён расчёт статистических характеристик текста, подтверждена применимость формул Хартли и Шеннона для оценки информации, а также сделаны выводы о наличии избыточности в естественном языке.